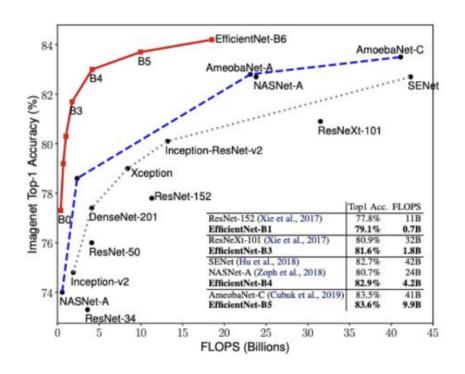
EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks 논문 오픈소스 분석



- EfficientNet은 ImageNet 데이터셋에서 매우 높은 정확도를 기록했습니다.
 ImageNet에서 기존 ConvNet보다 8.4배 작으면서 6.1배 빠르고 더 높은 정확도를
 얻었습니다. 예를 들어, EfficientNet-B4는 4.2B FLOPs(모델의 연산량)로 82.9%의
 정확도를 기록하며, 이는 NASNet-A와 유사한 정확도이지만 연산량은 절반
 이하입니다.
- EfficientNet은 Compound Scaling을 통해 모델의 크기, 깊이, 너비를 균형 있게 조절하여, 비슷한 정확도를 달성하면서도 다른 모델에 비해 훨씬 적은 연산량(FLOPs)과 파라미터를 사용합니다. EfficientNet-B0 모델은 5.3M 파라미터와 0.39B FLOPs를 사용하면서도 높은 성능을 보입니다.

Github link: https://github.com/tensorflow/tpu/tree/master/models/official/efficientnet

코드 실행 과정

0. 데이터셋을 불러오기 전에 Google Colab에 mount를 하고, 필요한 라이브러리를 import 하겠습니다.

```
[ ] from google.colab import drive
     drive.mount('efficientnet')
    import torch
    import torch.nn as nn
    import torch.nn.functional as F
    from torchsummary import summary
    from torch import optim
    from torchvision import datasets
    import torchvision.transforms as transforms
    from torch.utils.data import DataLoader
    from torchvision import models
    from torchvision import utils
    import matplotlib.pyplot as plt
    %matplotlib inline
    import numpy as np
    from torchsummary import summary
    import time
    import copy
```

1. 데이터셋 불러오기

- 데이터셋은 torchvision 패키지에서 제공하는 STL10 dataset을 이용하겠습니다.
STL10 dataset은 10개의 label을 갖으며 train dataset 5000개, test dataset 8000개로 구성됩니다.

```
[] # specify path to data
    path2data = '/content/efficientnet/MyDrive/data'

# if not exists the path, make the directory
    if not os.path.exists(path2data):
        os.mkdir(path2data)

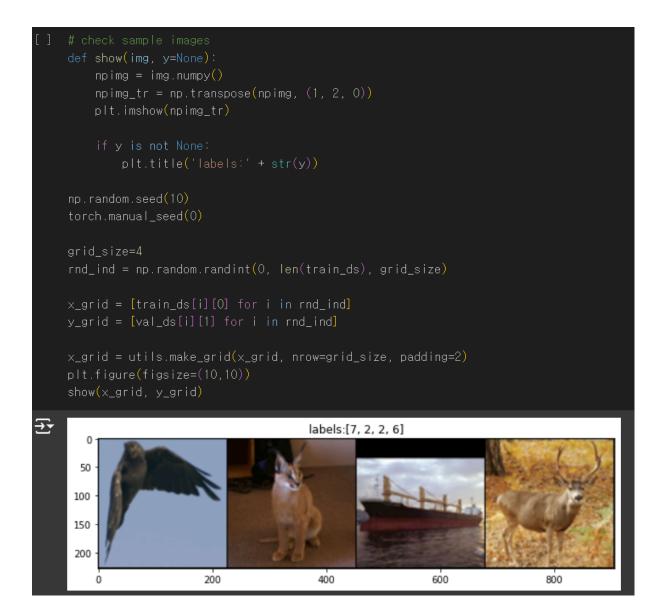
# load dataset
    train_ds = datasets.STL10(path2data, split='train', download=True, transform=transforms.ToTensor())
    val_ds = datasets.STL10(path2data, split='test', download=True, transform=transforms.ToTensor())

print(len(train_ds))
    print(len(val_ds))

Files already downloaded and verified
Files already downloaded and verified
5000
8000
```

- 랜덤하게 선택된 샘플 이미지를 그리드로 만들어 시각화하여 데이터의 형태와 레이블을 확인합니다.

이 작업을 통해 데이터셋의 전처리가 제대로 되었는지, 이미지 크기가 맞는지확인합니다.



2. 모델 구축하기

코드는 https://github.com/zsef123/EfficientNets-PyTorch/blob/master/models/effnet.py 를 참고했습니다.

https://github.com/katsura-jp/efficientnet-pytorch/blob/master/model/efficientnet.py

- Swish Activation
 - Swish 함수는 입력값에 sigmoid를 곱하여 비선형성을 적용하는 활성화 함수입니다.
- SEBlock
 - SEBlock은 채널별 중요도를 학습하여 중요한 채널을 강조하고 덜 중요한 채널을

억제하는 모듈입니다. Squeeze 단계에서 채널별 평균값을 구하고, Excitation 단계에서 중요도를 계산해 입력 텐서에 적용합니다.

MBConv

MBConv는 EfficientNet의 기본 빌딩 블록으로, Depthwise Convolution과 SEBlock을 결합하여 채널별 정보를 강화합니다. 확장 비율로 채널을 늘린 뒤, SEBlock을 적용하고 최종적으로 입력 크기로 다시 축소합니다.

```
class MBConv(nn.Module):
         expand = 6
         def __init__(self, in_channels, out_channels, kernel_size, stride=1, se_scale=4, p=0.5):
    super().__init__()
              self.p = torch.tensor(p).float() if (in_channels == out_channels) else torch.tensor(1).float()
              self.residual = nn.Sequential(
                  nn.Conv2d(in_channels, in_channels * MBConv.expand, 1, stride=stride, padding=0, bias=False),
                  nn.BatchNorm2d(in_channels * MBConv.expand, momentum=0.99, eps=1e-3),
                  Swish(),
                  nn.Conv2d(in_channels * MBConv.expand, in_channels * MBConv.expand, kernel_size=kernel_size, stride=1, padding=kernel_size//2, bias=False, groups=in_channels*MBConv.expand), nn.BatchNorm2d(in_channels * MBConv.expand, momentum=0.99, eps=1e-3),
             self.se = SEBlock(in_channels * MBConv.expand, se_scale)
             self.project = nn.Sequential(
                  nn.Conv2d(in_channels*MBConv.expand, out_channels, kernel_size=1, stride=1, padding=0, bias=False),
                  nn.BatchNorm2d(out channels, momentum=0.99, eps=1e-3)
             self.shortcut = (stride == 1) and (in_channels == out_channels)
         def forward(self, x):
             if self.training:
                      return x
            x_shortcut = x
x_residual = self.residual(x)
             x_se = self.se(x_residual)
             x = x_se * x_residual
              x = self.project(x)
             if self.shortcut:
                  x= x_shortcut + x
             return x
     if __name__ == '__main__':
        x = torch.randn(3, 16, 24, 24)
        model = MBConv(x.size(1), x.size(1), 3, stride=1, p=1)
         model.train()
         output = model(x)
         x = (output == x)
         print('output size:', output.size(), 'Stochastic depth:', x[1,0,0,0])
```

출력값: output size: torch.Size([3, 16, 24, 24]) Stochastic depth: tensor(False)

- SepConv

SepConv는 Depthwise Convolution과 SEBlock을 결합해 채널별 정보를 학습하는 모듈입니다.

입력과 출력 크기가 같으면 잔차 연결(residual connection)을 통해 성능을 보강합니다.

```
super()._init_()
# first SepConv is not using stochastic depth
            self.p = torch.tensor(p).float() if (in_channels == out_channels) else torch.tensor(1).float()
             self.residual = nn.Sequential(
                nn.Conv2d(in_channels * SepConv.expand, in_channels * SepConv.expand, kernel_size=kernel_size,
                stride=1, padding=kernel_size//2, bias=False, groups=in_channels*SepConv.expand), nn.BatchNorm2d(in_channels * SepConv.expand, momentum=0.99, eps=1e-3),
                 Swish()
            self.se = SEBlock(in_channels * SepConv.expand, se_scale)
            self.project = nn.Sequential(
                 nn.Conv2d(in_channels*SepConv.expand, out_channels, kernel_size=1, stride=1, padding=0, bias=False),
                 nn.BatchNorm2d(out_channels, momentum=0.99, eps=1e-3)
            self.shortcut = (stride == 1) and (in_channels == out_channels)
        def forward(self, x):
            if self.training:
                     return x
         x_shortcut = x
x_residual = self.residual(x)
            x_se = self.se(x_residual)
            x = x_se * x_residual
            x = self.project(x)
            if self.shortcut:
                x= x_shortcut + x
    if __name_
        x = torch.randn(3, 16, 24, 24)
        model = SepConv(x.size(1), x.size(1), 3, stride=1, p=1)
        model.train()
      output = model(x)
        print('output size:', output.size(), 'Stochastic depth:', x[1,0,0,0])
```

출력값: output size: torch.Size([3, 16, 24, 24]) Stochastic depth: tensor(False)

EfficientNet 클래스 요약 설명

- 클래스 개요

이 클래스는 EfficientNet 모델을 구현하며, 사용자 지정 파라미터(num_classes, width_coef, depth_coef, 등)를 통해 모델의 폭, 깊이, 확장 비율을 조정할 수 있습니다.

- 초기화 함수 (__init__)

채널, 반복 횟수 및 스트라이드 설정
 각 스테이지별 채널 크기, 반복 횟수, 스트라이드, 커널 크기를 정의하고,
 width coef와 depth coef로 이를 조정합니다.

Stochastic Depth

stochastic_depth를 활성화하면, 레이어 드롭 확률을 단계적으로 계산하여 적용합니다.

- 모듈 생성
 - 초기 업샘플링 레이어 (Upsample)
 - 첫 번째 스테이지: 일반 컨볼루션
 - 나머지 스테이지: SepConv 또는 MBConv를 사용하는 블록 반복 구조
 - 최종 스테이지: 1x1 컨볼루션과 활성화 함수 Swish
 - 풀링, 드롭아웃, 선형 계층을 통해 출력 클래스 수에 맞게 매핑

- Forward 함수

○ 입력 이미지를 업샘플링 후, 9개의 스테이지를 거쳐 최종 출력 확률을 계산합니다.

- _make_Block 함수

- o block 타입(SepConv 또는 MBConv)의 레이어를 반복하여 스테이지를 생성합니다.
- 첫 번째 레이어만 지정된 스트라이드를 적용하고, 이후에는 1로 설정.

```
ss EfficientNet(nn.Module):

def __init__(self, num_classes=10, width_coef=1., depth_coef=1., scale=1., dropout=0.2, se_scale=4, stochastic_depth=False, p=0.5):
    super().__init__()
    channels = [32, 16, 24, 40, 80, 112, 192, 320, 1280]
    repeats = [1, 2, 2, 3, 3, 4, 1]
    strides = [1, 2, 2, 2, 1, 2, 1]
    kernel_size = [3, 3, 5, 3, 5, 5, 3]
    depth = depth_coef
    width = width_coef
     channels = [int(x*width) for x in channels]
repeats = [int(x*depth) for x in repeats]
     if stochastic_depth:
           self.step = (1 - 0.5) / (sum(repeats) - 1)
           self.step = 0
     self.upsample = nn.Upsample(scale_factor=scale, mode='bilinear', align_corners=False)
     self.stage1 = nn.Sequential(
           nn.Conv2d(3, channels[0],3, stride=2, padding=1, bias=False), nn.BatchNorm2d(channels[0], momentum=0.99, eps=1e-3)
     self.stage2 = self.\_make\_Block(SepConv, repeats[0], channels[0], channels[1], kernel\_size[0], strides[0], se\_scale) \\
      self.stage3 = self._make_Block(MBConv, repeats[1], channels[1], channels[2], kernel_size[1], strides[1], se_scale)
      self.stage4 = self._make_Block(MBConv, repeats[2], channels[2], channels[3], kernel_size[2], strides[2], se_scale)
      self.stage5 = self._make_Block(MBConv, repeats[3], channels[3], channels[4], kernel_size[3], strides[3], se_scale)
     self.stage6 = self._make_Block(MBConv, repeats[4], channels[4], channels[5], kernel_size[4], strides[4], se_scale)
     self.stage7 = self._make_Block(MBConv, repeats[5], channels[5], channels[6], kernel_size[5], strides[5], se_scale)
     self.stage8 = self._make_Block(MBConv, repeats[6], channels[6], channels[7], kernel_size[6], strides[6], se_scale)
     self.stage9 = nn.Sequential(
    nn.Conv2d(channels[7], channels[8], 1, stride=1, bias=False),
    nn.BatchNorm2d(channels[8], momentum=0.99, eps=1e-3),
     self.avgpool = nn.AdaptiveAvgPool2d((1,1))
     self.dropout = nn.Dropout(p=dropout)
self.linear = nn.Linear(channels[8], num_classes)
def forward(self, x):
    x = self.upsample(x)
x = self.stage1(x)
    x = self.stage2(x)
x = self.stage3(x)
     x = self.stage4(x)
     x = self.stage5(x)
x = self.stage6(x)
    x = self.stage7(x)
x = self.stage8(x)
      x = self.stage9(x)
     x = self.avgpool(x)
    x = self.dropout(x)
x = self.linear(x)
    return x
def _make_Block(self, block, repeats, in_channels, out_channels, kernel_size, stride, se_scale):
    strides = [stride] + [1] * (repeats - 1)
     layers = []
for stride in strides:
          layers. append (block (in\_channels, out\_channels, kernel\_size, stride, se\_scale, self.p)) in\_channels = out\_channels
           self.p -= self.step
     return nn.Sequential(*layers)
```

- EfficientNet Variants 함수

efficientnet_b0부터 efficientnet_b7까지 EfficientNet의 8가지 버전을 생성합니다.

각 함수는 width_coef, depth_coef, scale, dropout 등 다양한 파라미터로 모델의 폭, 깊이, 입력 크기 스케일링을 조정합니다.

- B0: 기본 모델 (폭: 1.0, 깊이: 1.0)
- B7: 가장 큰 모델 (폭: 2.0, 깊이: 3.1, 더 큰 입력 크기, 더 높은 드롭아웃)

```
def efficientnet_b0(num_classes=10):
     return EfficientNet(num_classes=num_classes, width_coef=1.0, depth_coef=1.0, scale=1.0,dropout=0.2, se_scale=4)
 def efficientnet_b1(num_classes=10):
     return EfficientNet(num_classes=num_classes, width_coef=1.0, depth_coef=1.1, scale=240/224, dropout=0.2, se_scale=4)
def efficientnet_b2(num_classes=10):
     return EfficientNet(num_classes=num_classes, width_coef=1.1, depth_coef=1.2, scale=260/224., dropout=0.3, se_scale=4)
def efficientnet_b3(num_classes=10):
     return EfficientNet(num_classes=num_classes, width_coef=1.2, depth_coef=1.4, scale=300/224, dropout=0.3, se_scale=4)
def efficientnet_b4(num_classes=10):
      return EfficientNet(num_classes=num_classes, width_coef=1.4, depth_coef=1.8, scale=380/224, dropout=0.4, se_scale=4)
def efficientnet_b5(num_classes=10):
     return EfficientNet(num_classes=num_classes, width_coef=1.6, depth_coef=2.2, scale=456/224, dropout=0.4, se_scale=4)
def efficientnet_b6(num_classes=10):
    return EfficientNet(num_classes=num_classes, width_coef=1.8, depth_coef=2.6, scale=528/224, dropout=0.5, se_scale=4)
def efficientnet_b7(num_classes=10):
    return EfficientNet(num_classes=num_classes, width_coef=2.0, depth_coef=3.1, scale=600/224, dropout=0.5, se_scale=4)
if __name__ == '__main__':
    device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
    x = torch.randn(3, 3, 224, 224).to(device)
model = efficientnet_b0().to(device)
    output = model(x)
```

출력값: output size: torch.Size([3, 10])

- 모델 초기화 및 장치 설정
 efficientnet_b0() 모델을 초기화하고, 학습에 사용할 장치(CPU/GPU)로 모델을 이동시킵니다.
- 모델 구조 출력 summary() 함수를 사용하여 입력 크기 (3, 224, 224)에 대한 모델의 구조, 계층별

이를 통해 모델의 구조와 복잡도를 확인할 수 있습니다.

파라미터 수 및 총 파라미터 수를 출력합니다.

# print model summary model = efficientnet_b0().to(device) summary(model, (3,224,224), device=device.type) Layer (type)				
Upsample-1 [-1, 3, 224, 224] 0 Conv2d-2 [-1, 32, 112, 112] 864 BatchNorm2d-3 [-1, 32, 112, 112] 64 Conv2d-4 [-1, 32, 112, 112] 288 BatchNorm2d-5 [-1, 32, 112, 112] 64 Sigmoid-6 [-1, 32, 112, 112] 0	[]	model = efficientnet_b		
Conv2d-2 [-1, 32, 112, 112] 864 BatchNorm2d-3 [-1, 32, 112, 112] 64 Conv2d-4 [-1, 32, 112, 112] 288 BatchNorm2d-5 [-1, 32, 112, 112] 64 Sigmoid-6 [-1, 32, 112, 112] 0 Swish-7 [-1, 32, 112, 112] 0		 Layer (type) 	 Output Shape	Param #
AdaptiveAvgPool2d-8		Conv2d-2 BatchNorm2d-3 Conv2d-4 BatchNorm2d-5 Sigmoid-6 Swish-7 AdaptiveAvgPool2d-8 Linear-9 Sigmoid-10 Swish-11 Linear-12 Sigmoid-13 SEBlock-14 Conv2d-15 BatchNorm2d-16 SepConv-17 Conv2d-18 BatchNorm2d-19 Sigmoid-20 Swish-21	[-1, 32, 112, 112] [-1, 32, 112, 112] [-1, 32, 112, 112] [-1, 32, 112, 112] [-1, 32, 112, 112] [-1, 32, 112, 112] [-1, 128] [-1, 128] [-1, 128] [-1, 128] [-1, 32] [-1, 32] [-1, 32] [-1, 32] [-1, 16, 112, 112] [-1, 16, 112, 112] [-1, 96, 56, 56] [-1, 96, 56, 56] [-1, 96, 56, 56] [-1, 96, 56, 56]	864 64 288 64 0 0 0 4,224 0 0 4,128 0 0 512 32 0 1,536 192 0

3. 학습하기

- 손실 함수 및 최적화 정의

CrossEntropyLoss를 사용하여 손실을 계산하며, Adam 최적화 기법과 학습률 조정 스케줄러(ReduceLROnPlateau)를 적용합니다.

- 미니배치 손실 및 정확도 계산
 미니배치 단위로 손실을 계산하고 역전파를 통해 가중치를 업데이트하며, 예측 정확도를 계산합니다.
- 에포크 단위 손실 및 검증
 에포크 전체에 대해 훈련 및 검증 데이터를 통해 손실과 정확도를 계산합니다.
- 모델 훈련 및 저장
 가장 낮은 검증 손실 기준으로 최적의 가중치를 저장하며, 학습률 조정을 통해 성능을 최적화합니다.

```
# define loss function, optimizer, lr_scheduler
loss_func = nn.CrossEntropyLoss(reduction='sum')
opt = optim.Adam(model.parameters(), lr=0.01)
  from torch.optim.lr_scheduler import ReduceLROnPlateau lr_scheduler = ReduceLROnPlateau(opt, mode='min', factor=0.1, patience=10)
a get current Ir
def get_lr(opt):
    for param_group in opt.param_groups:
        return param_group['lr']
# calculate the metric per mini-batch
def metric_batch(output, target):
    pred = output.argmax(1, keepdim=True)
    corrects = pred.eq(target.view_as(pred)).sum().item()
    return corrects
# calculate the loss per mini-batch
def loss_batch(loss_func, output, target, opt=None):
    loss_b = loss_func(output, target)
    metric_b = metric_batch(output, target)
         if opt is not None:
    opt.zero_grad()
    loss_b.backward(
    opt.step()
# calculate the loss per epochs
def loss.epoch(model, loss_func, dataset_dl, sanity_check=False, opt=None):
    running_loss = 0.0
    running_metric = 0.0
    len_data = len(dataset_dl.dataset)
          for xb, yb in dataset_d1:
    xb = xb.to(device)
    yb = yb.to(device)
    output = model(xb)
                  loss_b, metric_b = loss_batch(loss_func, output, yb, opt)
                   running_loss += loss_b
                 if metric_b is not None:
    running_metric += metric_b
          loss = running_loss / len_data
metric = running_metric / len_data
return loss, metric
# function to start training

def train_val(model, params);

num_epochs=params['num_epochs']

loss_func=params['loss_func']

opt=params['optimizer']

train_dl=params['train_dl']

val_dl=params['rain_dl']

sanity_check=params['sanity_check']

lr_scheduler=params['lr_scheduler']

pathZweights=params['pathZweights']
          loss_history = {'train': [], 'val': []}
metric_history = {'train': [], 'val': []}
          best_loss = float('inf')
best_model_wts = copy.deepcopy(model.state_dict())
start_time = time.time()
          for epoch in range(num_epochs):
    current_lr = get_lr(opt)
    print('Epoch {}/{}, current lr= {}'.format(epoch, num_epochs-1, current_lr))
                   model.train()
train_loss, train_metric = loss_epoch(model, loss_func, train_dl, sanity_check, opt)
loss_history['train'].append(train_loss)
metric_history['train'].append(train_metric)
                   model.eval()
with torch.no_grad():
    val_loss, val_metric = loss_epoch(model, loss_func, val_dl, sanity_check)
loss_history['val'].append(val_loss)
metric_history['val'].append(val_metric)
                   if val_loss < best_loss:
  best_loss = val_loss
  best_model_wts = copy.deepcopy(model.state_dict())
  torch.save(model.state_dict(), pathZweights)
  print('Copied best model weights!')</pre>
                   lr_scheduler.step(val_loss)
if current_ir != get_lr(opt):
    print('Loading best model weights!')
    model.load_state_dict(best_model_wts)
                    print('train loss: %.6f, val loss: %.6f, accuracy: %.2f, time: %.4f min' %(train_loss, val_loss, 100*val_metric, (time.time()-start_time)/60))
print('-'*10)
           model.load_state_dict(best_model_wts)
return model, loss_history, metric_history
```

- 모델 학습을 위한 설정을 정의하고 필요한 디렉토리를 생성하여 학습을 준비하는 코드입니다.

```
[] # define the training parameters
    params_train = {
        'num_epochs':100,
        'optimizer':opt,
        'loss_func':loss_func,
        'train_dl':train_dl,
        'val_dl':val_dl,
        'sanity_check':False,
        'lr_scheduler':lr_scheduler,
        'path2weights':'./models/weights.pt',
}

# check the directory to save weights.pt
def createFolder(directory):
        try:
        if not os.path.exists(directory):
            os.makedirs(directory)
        except OSerror:
            print('Error')
        createFolder('./models')

[] model, loss_hist, metric_hist = train_val(model, params_train)
```

```
■ model, loss_hist, metric_hist = train_val(model, params_train)
■ Epoch 0/19, current Ir= 0.01
Copied best model weights!
train loss: 1.507311, val loss: 2.022092, accuracy: 29.46, time: 0.5537 min
Epoch 1/19, current Ir= 0.01
Copied best model weights!
train loss: 1.502268, val loss: 1.713452, accuracy: 33.74, time: 1.1052 min
Epoch 2/19, current Ir= 0.01
train loss: 1.432284, val loss: 1.850826, accuracy: 34.46, time: 1.6430 min
Epoch 3/19, current Ir= 0.01
Copied best model weights!
train loss: 1.410226, val loss: 1.549302, accuracy: 38.41, time: 2.1956 min
Epoch 4/19, current Ir= 0.01
train loss: 1.381581, val loss: 1.884781, accuracy: 36.20, time: 2.7360 min
Epoch 5/19, current Ir= 0.01
train loss: 1.331858, val loss: 1.987151, accuracy: 38.57, time: 3.2770 min
Epoch 6/19, current Ir= 0.01
train loss: 1.282874, val loss: 1.943976, accuracy: 40.51, time: 3.8162 min
Epoch 7/19, current Ir= 0.01
Loading best model weights!
train loss: 1.238939, val loss: 2.035488, accuracy: 41.15, time: 4.3620 min
Epoch 8/19, current Ir= 0.001
train loss: 1.261815, val loss: 1.815406, accuracy: 38.90, time: 4.9073 min
Epoch 8/19, current Ir= 0.001
train loss: 1.261815, val loss: 1.815406, accuracy: 38.90, time: 4.9073 min
Epoch 8/19, current Ir= 0.001
```

```
Epoch 8/19, current Ir= 0.001
train loss: 1.261815, val loss: 1.815406, accuracy: 38.90, time: 4.9073 min
Epoch 9/19, current Ir= 0.001
Copied best model weights!
train loss: 1.160707, val loss: 1.412762, accuracy: 47.58, time: 5.4557 min
Epoch 10/19, current Ir= 0.001
train loss: 1.115870, val loss: 1.814790, accuracy: 43.15, time: 5.9984 min
Copied best model weights!
train loss: 1.093127, val loss: 1.326927, accuracy: 49.76, time: 6.5489 min
train loss: 1.061364, val loss: 1.632945, accuracy: 44.77, time: 7.0912 min
Epoch 13/19, current | r= 0.001
train loss: 1.039094, val loss: 1.539156, accuracy: 46.35, time: 7.6331 min
Epoch 14/19, current Ir= 0.001
train loss: 1.001268, val loss: 1.504423, accuracy: 47.33, time: 8.1757 min
Epoch 15/19, current Ir= 0.001
train loss: 0.966988, val loss: 1.548535, accuracy: 45.30, time: 8.7132 min
train loss: 0.926754, val loss: 1.696836, accuracy: 47.27, time: 9.2518 min
train loss: 0.870007, val loss: 1.743425, accuracy: 44.82, time: 9.7910 min
Epoch 18/19, current Ir= 0.001
train loss: 0.838045, val loss: 1.575955, accuracy: 47.94, time: 10.3278 min
```

4. 성능 평가하기

Train-Val Loss는 초기 몇 Epoch 동안 빠르게 감소하며 모델이 학습됨을 보여줍니다. 하지만 Epoch 12 이후 검증 손실이 증가하는 과적합 경향이 나타납니다. 이는 모델이 훈련 데이터에 적합했지만 검증 데이터에 대한 일반화가 부족함을 의미합니다.

