오픈소스 연구논문 분석

소프트웨어학과_2022315965_문준원

사전 학습된 VGG-16 모델 가중치 활용

본 연구에서는 OxfordNet (VGG-16)네트워크를 R-CNN모델에 적용하여 성능을 향상시키고자 하였습니다. 이를 위해 Caffe의 Model Zoo플랫폼에서 제공하는 VGG_ILSVRC_16_layers모델의 사전 학습된 가중치를 사용하였습니다. 연구진은 이 가중치를 R-CNN 모델에 불러와, 특정 작업에 맞춰 미세 조정(fine-tuning)을 수행했습니다. 이를 통해 모델을 처음부터학습시키는 비용을 줄이고, 효율적으로 높은 성능을 낼 수 있었습니다.

구글코랩을 사용하여 실습해 보았습니다.

 Google Drive 연결 및 라이브러리 설지 Google Colab을 사용할 경우, 아래와 같이 Google Drive를 마운트하고, 필요한 라이브러리 를 설치 및 불러옵니다.

```
# Attempting to mount the drive with a longer timeous
drive.mount('_content/vggnet', force_remount=True, timeous_ms=300000) # increased timeout to 5 minutes ($00000 milliseconds)

# If it still fails, try this alternative:
# from google.colab import suth
# auth.authenticate_user()

# drive.mount('_content/vggnet')

**Mounted at /content/vggnet
```

2. 라이브러리 불러오기 이미지 전처리, 데이터 로드, 학습에 필요한 라이브러리를 불러옵니다.

```
[4] # import torch
import torch import torch.nn as nn
import torch.nn.functional as F
from torchsummary import summary
from torch import optim
from torch import datasets, transforms
from torch.utils.data import DataLeader
import numby as np
import os
import matplotlib.pyplot as plt

# Enable inline plotting
%natplotlib inline
```

3. STL-10 데이터켓 블러오기 및 정규화 STL-10 데이터셋을 다운로드하고, **정규화(mean, skt)를** 수행한 후 FiveCrop 중강을 적용합니다.

```
Figure 1 Set: the data path path path 2 Set: the data path 2 Set: th
```

4. DataLoader 설정 데이터를 학습에 사용할 수 있도록 DataLoader로 변환합니다.

```
# Create DataLoader
train_dl = DataLoader(train_ds, batch_size=4, shuffle=True)
val_dl = DataLoader(val_ds, batch_size=4, shuffle=False)
```

5. VGG 모델 정의 VGG16 모델을 정의하고, 학습을 위한 가중치를 초기화합니다.

```
# Define VSB network structure
 VGG_types = [
          VGG16': [64, 64, 'M', 126, 128, 'N', 256, 256, 256, 'M', 512, 512, 512, 'M', 512, 512, 512, 'M']
 class V86_net(nn.Module):
       def __init__(self, model, in_channels=8, num_classes=10, init_weights=True):
    super(Y66_net, self).__init__()
    self.in_channels = in_channels
    self.conv_layers = self.create_conv_layers(Y66_types[model])
             self.fc_layers = nn.Sequential(
nn.Linear(512 + 7 + 7, 4086),
                    nn.ReLU(),
                    nn.Bropout(p=0.5),
nn.Linear(4096, 4098),
                    nn.ReLU(),
                    nn.Dropout(p=0.5),
nn.Linear(4086, num_classes),
              if init_weights:
                    self._initialize_weights()
       def forward(self, x):
             x = self.conv_layers(x)
x = x.vlew(x.size(0), -1)
              x = self.fc_layers(x)
              return x
       def _initialize_weights(self):
   for m in self.modules():
                    If Isinstance(m, nn.Conv2d):
                         nn.init.kaiming_normal_(m.weight, mode='fan_out', nonlinearity='relu')
if m.blas is not None:
                   nn.init.constant_(m.bias, 0)
elif isinstance(m, nn.BatchNorm2d):
nn.init.constant_(m.weight, 1)
                   nn.init.comstant_(m.blas, 0)
ellf isinstance(m.nn.Linear):
nn.init.normal_(m.weight, 0, 0.01)
                          nn.init.constant_(m.bias, 0)
```

```
def create_conv_layers(self, architecture):
        layers = []
        in_channels = self.in_channels
        for x in architecture:
            If type(x) == int:
                out\_channels = x
                layers += [nn.Conv2d(in_channels, out_channels, kernel_size=3, stride=1, padding=1),
                           nn.BatchNorm2d(out_channels),
                           nn.ReLU(Inplace=True)]
                in_channels = out_channels
            elif x == 'M':
                layers += [nn.MaxPool2d(kernel_size=2, stride=2)]
        return nn. Sequential (*layers)
# Initialize model
device = 'cuda' if torch.cuda.is_available() else 'cpu'
model = Y6G_net('Y6G16', in_channels=3, num_classes=10, init_weights=True).to(device)
summary(model, (3, 224, 224), device=device) # Changed: removed .type
```

출력결과:

Layer (type)	Output Shape	Param #
Conv2d-1	[-1, 64, 224, 224]	1,792
BatchNorm2d-2	[-1, 64, 224, 224]	128
ReLU-3	[-1, 64, 224, 224]	0
Conv2d-4	[-1, 64, 224, 224]	36,928
BatchNorm2d-5	[-1, 64, 224, 224]	128
ReLU-6	[-1, 64, 224, 224]	0
MaxPool2d-7	[-1, 64, 112, 112]	0
Conv2d-8	[-1, 128, 112, 112]	73,856
BatchNorm2d-9	[-1, 128, 112, 112]	256
ReLU-10	[-1, 128, 112, 112]	0
Conv2d-11	[-1, 128, 112, 112]	147,584
BatchNorm2d-12	[-1, 128, 112, 112]	256
ReLU-13	[-1, 128, 112, 112]	0
MaxPool2d-14	[-1, 128, 56, 56]	0
Conv2d-15	[-1, 256, 56, 56]	295, 168
BatchNorm2d-16	[-1, 256, 56, 56]	512
ReLU-17	[-1, 256, 56, 56]	0
Conv2d-18	[-1, 256, 56, 56]	590,080
BatchNorm2d-19	[-1, 256, 56, 56]	512
ReLU-20		0
	[-1, 256, 56, 56]	
Conv2d-21	[-1, 256, 56, 56]	590,080
BatchNorm2d-22	[-1, 256, 56, 56]	512
ReLU-23	[-1, 256, 56, 56]	0
MaxPool2d-24	[-1, 256, 28, 28]	0
Conv2d~25	[-1, 512, 28, 28]	1,180,160
BatchNorm2d-26	[-1, 512, 28, 28]	1,024
ReLU-27	[-1, 512, 28, 28]	0
Conv2d-28	[-1, 512, 28, 28]	2,359,808
BatchNorm2d-29	[-1, 512, 28, 28]	1,024
ReLU-30	[-1, 512, 28, 28]	0
Conv2d-31	[-1, 512, 28, 28]	2,359,808
BatchNorm2d-32	[-1, 512, 28, 28]	1,024
ReLU-33	[-1, 512, 28, 28]	0
MaxPool2d-34	[-1, 512, 14, 14]	0
Conv2d-35	[-1, 512, 14, 14]	2,359,808
BatchNorm2d-36	[-1, 512, 14, 14]	1,024
ReLU-37	[-1, 512, 14, 14]	0 000
Conv2d-38	[-1, 512, 14, 14]	2,359,808
BatchNorm2d-39	[-1, 512, 14, 14]	1,024
ReLU-40	[-1, 512, 14, 14]	0
Conv2d-41	[-1, 512, 14, 14]	2,359,808
BatchNorm2d-42	[-1, 512, 14, 14]	1,024
ReLU-43	[-1, 512, 14, 14]	0
MaxPool2d-44	[-1, 512, 7, 7]	0
Linear-45	[-1, 4096]	102,764,544
ReLU-46	[-1, 4096]	0
Dropout-47	[-1, 4096]	Ō
Linear-48	[-1, 4096]	16,781,312
ReLU-49	[-1, 4096]	0,701,312
Dropout-50	[-1, 4096]	0
Linear-51	[-1, 10]	40,970

Total params: 134,309,962 Trainable params: 134,309,962 Non-trainable params: 0 6. 모델 학습 및 평가 학습, 평가 루프는 성능을 측정하는 중요한 단계입니다. 아래는 간단한 학습 루프 예시입니다.

```
from tadm Import tadm # 진행 바 표시를 위해 tadm 라이브러리 사용
# Define optimizer and loss function
import time
from torch import repeat_interleave
optimizer = optim.Adam(model.parameters(), Ir=0.001)
criterion = nn.CrossEntropyLoss()
# Define number of epochs
num_epochs = 10 # 원하는 에포크 수 설정
for epoch in range(num_epochs):
    model.train()
    train_loss = 0.0
    train_correct = 0
   total_samples = 0
   start_time = time.time()
    # tqdm을 사용하여 진행 바 표시
    with tqdm(total=ien(train_dl), desc=f"Epoch [epoch+1]/{num_epochs}*, unit="batch") as pbar:
        for images, labels in train_dl:
           images = images.to(device)
           labels = labels.to(device)
           # Forward pass
           outputs = model(images)
           loss = criterion(outputs, labels)
           train_loss += loss.item()
           # Calculate accuracy
           _, preds = torch.max(outputs, 1)
           train_correct += (preds == labels).sum().item()
           total_samples += labels.size(0)
           # Backward pass and optimize
           optimizer.zero_grad()
           loss.backward()
           optimizer.step()
           # tqdm 진행 바 업데이트
           pbar.update(1)
    # Calculate and print results for each epoch
    train_loss /= len(train_dl)
    train_accuracy = 100 * train_correct / total_samples
    train_time = time.time() - start_time
    print(f"Epoch {epoch+1}/{num_epochs}: "
         f"train loss: (train_loss: 4f), accuracy: (train_accuracy: 2f)%, "
          f"time: (train_time: 4f) s")
    print("--" * 10)
```

출력값: 본 연구에서는 VGG16 모델을 사용하여 학습을 진행했습니다. 하지만 VGG16 모델은 파라미터 수가 매우 많고, 연산량이 커서 Google Colab 환경의 자원으로는 제한된 에포크까지만 학습을 수행할 수 있었습니다. 특히, Colab의 GPU 메모리 한계와 학습시간이 길어지는 문제로 인해 에포크 설정 중 10 에포크까지만 실행이 가능했습니다. 실제 학습 결과, 에포크가 진행됨에 따라 손실값이 점차 줄어들고 정확도가 서서히 증가하는 경향을 보였으나, 자원 제약으로 인해 모델이 충분히 수렴하지 못한 상태에서 학습을 중단하게 되었습니다.

```
₹ Epoch 1/10
    train loss: 2.305832, accuracy: 9.88, time: 151.3181 s
    Epoch 2/10
    train loss: 2.306310, accuracy: 9.34, time: 151.5804 s
    train loss: 2.307419, accuracy: 9.02, time: 151.5708 s
    Epoch 4/10
    train loss: 2.304202, accuracy: 9.96, time: 151.6122 s
    Epoch 5/10
    train loss: 2.303574, accuracy: 9.50, time: 151.5158 s
    Epoch 6/10
    train loss: 2.303992, accuracy: 8.82, time: 151.5466 s
    Epoch 7/10
    train loss: 2.303563, accuracy: 9.62, time: 151.5048 s
    Epoch 8/10
    train loss: 2.303516, accuracy: 9.26, time: 151.2012 s
    Epoch 9/10
    train loss: 2.303282, accuracy: 9.66, time: 151.1494 s
    Epoch 10/10
    train loss: 2.303453, accuracy: 9.36, time: 151.3132 s
```